



机器学习 课程考试卷 (人工智能)

姓名: _____ 学号: _____

一、选择题 (每题 2 分, 共 10 分)

1. 下列哪个不是监督学习? (A) 线性回归 (B) 决策树 (C) 聚类分析 (D) 支持向量机
2. 在逻辑回归中, sigmoid 函数的输出范围是? (A) [0, 1] (B) [-1, 1] (C) [0, 10] (D) [-10, 10]
3. 下列哪个不是无监督学习? (A) K-均值聚类 (B) 主成分分析 (C) 决策树 (D) 关联规则挖掘
4. 在支持向量机 (SVM) 中, 我们寻找的是? (A) 最大间隔 (B) 最小间隔 (C) 最大重叠 (D) 最小重叠
5. 下列哪个不是深度学习? (A) 卷积神经网络 (B) 循环神经网络 (C) 决策树 (D) 生成对抗网络

二、简答题 (每题 5 分, 共 10 分)

1. 请简述机器学习和深度学习的关系。
2. 请简述监督学习和无监督学习的区别。

三、计算题 (共 10 分)

1. 给定数据集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$, 其中 x_i 是特征向量, y_i 是类别标签。假设我们使用线性模型 $f(x) = w \cdot x + b$ 进行分类, 其中 w 是权重向量, b 是偏置项。请写出该模型的损失函数, 并推导出权重 w 和偏置 b 的更新公式。

2. 给定数据集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$, 其中 x_i 是特征向量, y_i 是类别标签。假设我们使用决策树进行分类。请写出决策树的构建步骤。

3. 给定数据集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$, 其中 x_i 是特征向量, y_i 是类别标签。假设我们使用支持向量机 (SVM) 进行分类。请写出 SVM 的优化问题。

机器学习 课程考试卷 (人工智能)

姓名: _____ 学号: _____

一、选择题 (每题 2 分, 共 10 分)

1. 下列哪个不是监督学习? (A) 线性回归 (B) 决策树 (C) 聚类分析 (D) 支持向量机
2. 在逻辑回归中, sigmoid 函数的输出范围是? (A) [0, 1] (B) [-1, 1] (C) [0, 10] (D) [-10, 10]
3. 下列哪个不是无监督学习? (A) K-均值聚类 (B) 主成分分析 (C) 决策树 (D) 关联规则挖掘
4. 在支持向量机 (SVM) 中, 我们寻找的是? (A) 最大间隔 (B) 最小间隔 (C) 最大重叠 (D) 最小重叠
5. 下列哪个不是深度学习? (A) 卷积神经网络 (B) 循环神经网络 (C) 决策树 (D) 生成对抗网络

二、简答题 (每题 5 分, 共 10 分)

1. 请简述机器学习和深度学习的关系。
2. 请简述监督学习和无监督学习的区别。

三、计算题 (共 10 分)

1. 给定数据集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$, 其中 x_i 是特征向量, y_i 是类别标签。假设我们使用线性模型 $f(x) = w \cdot x + b$ 进行分类, 其中 w 是权重向量, b 是偏置项。请写出该模型的损失函数, 并推导出权重 w 和偏置 b 的更新公式。

2. 给定数据集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$, 其中 x_i 是特征向量, y_i 是类别标签。假设我们使用决策树进行分类。请写出决策树的构建步骤。

3. 给定数据集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$, 其中 x_i 是特征向量, y_i 是类别标签。假设我们使用支持向量机 (SVM) 进行分类。请写出 SVM 的优化问题。

决策树: 使用树状结构表示决策过程, 通过对特征的分类来进行分类。决策树易于理解, 能够处理分类和回归任务。

支持向量机 (SVM): 用于分类和回归任务的强大算法。SVM 通过找到将不同类别数据分隔开来的最佳超平面, 可以处理非线性问题的核函数。

朴素贝叶斯: 基于贝叶斯定理的分类算法, 在文本分类等领域应用广泛。它假设特征之间相互独立。

除此之外, 我还喜欢线性回归和逻辑回归等算法

5. 请回答以下问题:

- (1) 请简述线性判别分析 (Linear Discriminant Analysis) 学习方法的主要思想。
- (2) 小明参加某公司的面试, 他在面试中表现出色, 原本预计上该公司的面试通过率很高, 但面试结果却不尽如人意。请分析可能的原因。

(1) 线性判别分析学习方法的主要思想是: 将数据投影到一个低维空间中, 使得不同类别的样本在投影后的空间中尽可能地分开。同一类别的样本是尽可能地接近。LDA 的目标是通过最大化类间距离而最小化类内距离来实现分类的优化。

(2) 小明的面试情况可能存在以下原因导致面试结果不理想:

1. 数据分布不一致: 大量官方的测试集与小明自己的本地测试集可能具有不同的数据分布。经过过程中, 小明可能过度拟合了本地测试集的特征, 导致在官方测试集上的性能下降。
2. 可能的随机性: 机器学习算法中存在一定的随机性, 包括初始状态、随机采样等。在不同环境下, 即使特征和模型保持不变, 也可能出现微妙的性能变化。
3. 模型的非泛化能力较差: 模型本身的泛化能力较弱, 通过调参并不能提升模型整体性能。

图 1: 使用上述数据, 采用 103 算法进行分类。若以信息增益为准则选择属性, 则计算选择 (信息熵) 为划分属性时信息增益, 要求有计算过程, 用分数表示属性即可。如节点信息的信息熵可写为:

$$H(D) = -\sum_{i=1}^n p_i \log_2 p_i$$

图 2: 使用上述数据, 采用 103 算法进行分类。若以信息增益为准则选择属性, 则计算选择 (信息熵) 为划分属性时信息增益, 要求有计算过程, 用分数表示属性即可。如节点信息的信息熵可写为:

$$H(D) = -\sum_{i=1}^n p_i \log_2 p_i$$

(1) 使用上述数据, 采用 103 算法进行分类。若以信息增益为准则选择属性, 则计算选择 (信息熵) 为划分属性时信息增益, 要求有计算过程, 用分数表示属性即可。如节点信息的信息熵可写为:


图 1: 使用上述数据, 采用 103 算法进行分类。若以信息增益为准则选择属性, 则计算选择 (信息熵) 为划分属性时信息增益, 要求有计算过程, 用分数表示属性即可。如节点信息的信息熵可写为:

$$H(D) = -\sum_{i=1}^n p_i \log_2 p_i$$

图 2: 使用上述数据, 采用 103 算法进行分类。若以信息增益为准则选择属性, 则计算选择 (信息熵) 为划分属性时信息增益, 要求有计算过程, 用分数表示属性即可。如节点信息的信息熵可写为:

$$H(D) = -\sum_{i=1}^n p_i \log_2 p_i$$

2. 下图为采用不同核函数或不同的核函数子得到的 SVM 决策边界。假想心的实数表示记录每个图形对应的模型和参数了。请参照图展 (1) 小题的示例, 给下图中每个模型标出正确的图形。(每小题 2 分, 共 8 分)



$$(1) \min \left(\frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \right), \text{ s.t.}$$

$$\xi_i \geq 0, y_i (w^T x_i + w_0) \geq 1 - \xi_i, i = 1, \dots, N,$$

其中 $C = 0.1$ 。

答: 对应图 (c)

线性分界面, C 较小。

正则较大, $\|w\|$ 较小, Margin 较大。

支持向量较多

$$(2) \min \left(\frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \right), \text{ s.t.}$$

$$\xi_i \geq 0, y_i (w^T x_i + w_0) \geq 1 - \xi_i, i = 1, \dots, N,$$

其中 $C = 1$ 。

$$(3) \min \left(\sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j K(x_i, x_j) \right)$$

$$\text{ s.t. } 0 \leq \alpha_i \leq C, i = 1, \dots, N, \sum_{i=1}^N \alpha_i y_i = 0$$

$$\text{其中 } K(x, x') = x^T x' + (x^T x')^2.$$

$$(4) \min \left(\sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j K(x_i, x_j) \right)$$

$$\text{ s.t. } 0 \leq \alpha_i \leq C, i = 1, \dots, N, \sum_{i=1}^N \alpha_i y_i = 0$$

$$\text{其中 } K(x, x') = \exp\left(-\frac{1}{2} \|x - x'\|^2\right).$$

$$(5) \min \left(\sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j K(x_i, x_j) \right)$$

$$\text{ s.t. } 0 \leq \alpha_i \leq C, i = 1, \dots, N, \sum_{i=1}^N \alpha_i y_i = 0$$

$$\text{其中 } K(x, x') = \exp\left(-\frac{1}{2} \|x - x'\|^2\right).$$

(b)
答: 线性分界面, C 较大,
正则较小, $\|w\|$ 较大, Margin 较小
支持向量数目少

(d)
答: 非线性分界面, 决策边界为曲线
正则与核函数参数, 决策边界为曲线

(a)
答: RBF 核函数, 决策边界为曲线
 $C = 1$ 较大, 曲线更平滑

(c)
答: RBF 核函数, 决策边界为曲线
 $C = \frac{1}{2}$ 较小, 曲线更平滑

2024 上学期《机器学习》期末考试内容：

第 1 章·绪论

机器学习概念，监督学习与非监督学习，发展历程与应用现状；

第 2 章·模型评估与选择

经验误差、过拟合的理解、性能度量、真正例率（TPR）、假正例率（FPR）与查准率（P）及查全率（R）的定义、偏差与方差分解。

第 3 章·线性模型

对数几率回归的定义及概率表达式、线性回归及线性判别分析的思想、多分类学习。

第 4 章·决策树

划分选择：信息增益计算、剪枝处理。

第 5 章·神经网络

神经网络的完整的训练过程包括的三个方面、反向传播的概念、梯度消失与梯度爆炸。

第 6 章·支持向量机

算法基本思想、软间隔与正则化、带松弛因子的线性 SVM 分类器：

$$\min \left(\frac{1}{2} \|\mathbf{w}\|^2 + C \frac{1}{2} \sum_{i=1}^N \xi_i \right), \text{ s.t. } \xi_i \geq 0, y_i (\mathbf{w}^T \mathbf{x} + w_0) \geq 1 - \xi_i, i=1, \dots, N,$$
 中 C 的作用、线性与非线性支持向量机的图形判断（学习通作业）。

第 7 章·贝叶斯分类器

基本概念、朴素贝叶斯分类器训练过程及概率计算。

第 8 章·集成学习

集成学习的基本原理的理解、AdaBoost 及随机森林算法流程及伪代码、结合策略、多样性增强。