

机器学习A课程试卷

考试日期：2024年6月 日

考试类别：考试

考试时间： 分钟

题号	一	二	三	四	总分	统分签字
得分						

得分	
阅卷人	

一、判断题。（若为真，在括号内写“T”，为假写“F”；每空2分，共18分）

1. 赵同学去应聘某互联网公司算法工程师，面试官提问“回归和分类有什么相同和不同点”，他说了以下言论，请逐条判断是否正确。

(1) 回归问题和分类问题都是有监督学习的问题 ()

(2) 回归问题和分类问题都有可能发生过拟合 ()

2. SVM对噪声（如来自其他分布的噪声样本）鲁棒。 ()

3. 考虑带松弛因子的线性SVM分类器：

$$\min \left(\frac{1}{2} \|\mathbf{w}\|^2 + C \frac{1}{2} \sum_{i=1}^N \xi_i \right), \text{ s.t. } \xi_i \geq 0, y_i (\mathbf{w}^T \mathbf{x} + w_0) \geq 1 - \xi_i, i = 1, \dots, N,$$
 请判断下面有一些关于

某些变量随参数C的增大而变化的表述的正确性。

(1) 会有更多的训练样本被分错。 ()

(2) 间隔(Margin)不会增大。 ()

4. 从偏差-方差分解角度看，Bagging主要关注降低方差，Boosting主要关注减小偏差，同时降低方差。 ()

5. 在神经网络中，梯度消失是指在反向传播过程中，较浅层的神经元权重更新变化较小，导致学习变得非常缓慢。 ()

6. 朴素贝叶斯算法中的“朴素”指的是假设特征之间相互独立。 ()

7. 在一般情况下，给定 n 个数据点，如果其中一半用于训练，另一半用于测试，则训练误差和测试误差之间的差别会随着n的增加而减小。 ()

得分	
阅卷人	

二、填空题（每空2分，共22分）

8. 给定数据集 $D = \{(x_i, y_i)\}_{i=1}^N$ ，其中 $x_i = (x_{i1}, \dots, x_{id})$ 为输入特征包括 d 个属性，

$y_i \in \{0, 1\}$ 为标记值，定义对数几率回归（逻辑斯蒂回归，Logistic Regression）模

型: $\ln \frac{y}{1-y} = w'x + b$, 请写出概率表达式: $p(y=1|x) =$ _____.

$p(y=0|x) =$ _____。

9. 学习算法的性能“偏差-方差分解”是解释学习算法泛化性能的一中重要工具, 泛化误差可分解为_____、_____与噪声之和。

10. 决策树剪枝的基本策略有_____与_____。

11. 给定训练数据集 $D = \{(x_i, y_i)\}_{i=1}^N$, AdaBoost 可以理解为基于“加法模型”(additive

model)产生, 即基分类器 $h_i(x)$ 的线性组合 $H(x) = \sum_{i=1}^T \alpha_i h_i(x)$, 其中基分类器 $h_i(x)$

及权重系数 α_i 基于数据分布 D_i 迭代产生后, 设 $h_i(x)$ 的在数据集 D 上的分类错误率为

$\varepsilon_i = P_{x \sim D_i}(h_i(x) \neq y)$, 则权重更新公式为: $\alpha_i =$ _____。

12. 集成学习中为了增强个体学习器的多样性, 一般是在学习过程中针对数据样本引入随机性, 常见做法主要有_____、_____、输出表示扰动和算法参数扰动。

13. 在神经网络中, 一个完整的训练过程通常包括_____、反向传播和_____三个步骤。

得分	
阅卷人	

三、简答题 (共 36 分)

14. 监督学习和非监督学习有什么不同? (5 分)

15. 在年度的奥斯卡奖项揭晓之前, 老师问全班的 90 名学生, 今年谁将获得最佳导演、最佳男女主角。随后老师计算了每个学生的猜中率, 同时也统计了 90 名学生的投票结果。奖项揭晓后, 老师发现所有人的投票结果比任何一个学生的猜中率都高, 这种提高是偶然的吗? 请从机器学习的角度对上述结果进行解释。(8 分)

16. 什么是神经网络的反向传播? (5 分)

17. 根据下述表格, 用公式写出真正例率 (TPR)、假正例率 (FPR) 与查准率 (P) 及查

- $p(y = 1|x) = \frac{1}{1+\exp(-(w^T x + b))}$
- $p(y = 0|x) = \frac{\exp(-(w^T x + b))}{1+\exp(-(w^T x + b))}$

得分	
阅卷人	

四、问答题（共 2 小题，共 14 分）

19. 设有如下数据集：

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	硬挺	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

（1）使用上述数据集，采用 ID3 学习算法训练决策树，若以信息增益准则选择划分属性，请计算选择“色泽”作为划分属性的信息增益。要求有计算过程，用分数表示概率即可，如根节点的信息熵可写为：

$$\text{Ent}(D) = - \sum_{k=1}^2 p_k \log_2 p_k = -(\frac{8}{17} \log_2 \frac{8}{17} + \frac{9}{17} \log_2 \frac{9}{17})$$

不需要计算出信息增益最后结果的小数值。

6. (连线题, 25分)

SVM分类

下图为采用不同核函数或不同的松弛因子得到的svm决策边界。但粗心的实验者忘记记录每个图形对应的模型和参数了。请你帮忙给下面每个模型标出正确的图形。

